Insaf El Korachi

Étudiante en Master 2 Intelligence Artificielle et Science des Données

Stage PFE – Data Engineer

+212 663 604 950 | insaf2003elkorachi@gmail.com

insafelkorachi.netlify.app | github.com/Insaf-elkorachi | linkedin.com/in/insaf-el-korachi-400aaa2a3

Profil professionnel

Étudiante en Master 2 Intelligence Artificielle et Science des Données, orientée Data Engineering, avec une expérience en automatisation de workflows ETL avec dbt et Apache Airflow, et en exploitation de données Snowflake et PostgreSQL. Projets de traitement en temps réel avec Kafka et Spark Structured Streaming, et de gestion de données documentaires chez SONASID. Recherche un stage PFE en Data Engineering pour contribuer au développement de pipelines de données et à leur exploitation pour le reporting et l'IA.

Expériences professionnelles

Stagiaire ingénieure IA | SONASID **Juillet 2026 – Septembre 2026**

Projet : Plateforme intelligente de recrutement

Technologies : *Python, FastAPI, MongoDB, bases de données vectorielles, LLM, RAG, NLP, Power BI*

— Conception d'un flux d'analyse de CV pour l'évaluation et le matching au sein d'une plateforme de recrutement.
— Développement d'un workflow multi-agents pour automatiser le traitement des documents RH et orchestrer l'analyse.
— Développement d'un pipeline RAG intégrant MongoDB et la recherche vectorielle pour exploiter les documents RH.

Stagiaire ingénieure IA | SONASID **Mai 2026 – Juillet 2026**

Projet : Plateforme de sécurité industrielle AMAN

Technologies : *Python, FastAPI, SQLite, API REST, LLM, NLP, QR Codes*

— Développement d'une plateforme de collecte des signalements d'incidents industriels accessible par QR code.
— Implémentation d'un chatbot pour collecter et classifier les incidents, puis générer des rapports structurés.
— Intégration du stockage SQLite, de l'analyse des risques et de tableaux de bord pour le suivi des données de sécurité.

Stagiaire Data Analyst | Tanger Med Utilities **Avril 2025 – Juin 2025**

Technologies : *dbt, Apache Airflow, Snowflake, PostgreSQL, SQL, Power BI*

— Automatisation de workflows ETL avec dbt et Airflow pour transformer les données et orchestrer les pipelines.
— Exploitation de données Snowflake et PostgreSQL pour alimenter le reporting opérationnel et la prise de décision.
— Développement de tableaux de bord Power BI pour suivre les données opérationnelles et les indicateurs clés.

Projets

Détection du phishing par RAG et LLM

Technologies : *Python, Qwen2.5, RAG, FAISS, BM25, Sentence-BERT, Transformers*

— Conception d'un pipeline de recherche et d'analyse de textes pour classifier le phishing et analyser les menaces.
— Implémentation d'une recherche hybride combinant recherche lexicale BM25, embeddings Sentence-BERT et index vectoriel FAISS.
— Obtention d'une **accuracy de 80%** avec la recherche hybride et Qwen2.5.

Pipeline de streaming – Analyse des sentiments des avis Amazon

Technologies : *Python, Kafka, Spark Structured Streaming, Spark MLlib, Docker, Apache Airflow, NLP*

— Développement d'un pipeline de bout en bout pour le traitement en temps réel et la classification des avis Amazon.
— Intégration de Kafka et Spark Structured Streaming pour traiter les flux et l'inférence en temps réel, avec Docker et Airflow.
— Évaluation du modèle : **accuracy de 78,45%** et **F1-score de 79,69%**.

Formation

Master en Intelligence Artificielle et Science des Données **2025 – 2027**
Faculté des Sciences et Techniques de Tanger – deuxième année

Licence en Analyse de Données **2021 – 2025**
Faculté des Sciences et Techniques de Tanger

Baccalauréat en Sciences Mathématiques, option A **2020 – 2021**
Lycée Ibn Al Haytham, Al Aaroui

Compétences techniques

Programmation & traitement de données : Python, SQL, Pandas, NumPy, nettoyage et transformation de données.

Pipelines & orchestration : ETL, dbt, Apache Airflow, automatisation de workflows.

Big Data & streaming : Apache Kafka, Spark Structured Streaming, Spark MLlib.

Bases de données & entrepôts : Snowflake, PostgreSQL, MySQL, MongoDB, SQLite, Firestore, pgVector.

Développement & Cloud : Docker, Linux, Git, GitHub, FastAPI, API REST, Google Cloud Platform.

BI & IA : Power BI, Machine Learning, NLP, LLM, RAG, embeddings, Scikit-learn, Hugging Face Transformers.

Langues

Arabe : C2 | Français : B2 | Anglais : B2